

AI 音樂及人聲研究-RVC-WebUI 實作紀錄
中原大學 電機工程學系 潘宇綸

一、嘗試使用 RVC-WebUI 模擬

1. 前言

學生在研究老師於 2025 年底發布之研究「使用 AI 歌聲轉換技術將〈大醉俠〉主題曲轉換為胡金銓導演聲線之實驗研究」(以下稱之為「研究資料」)，見老師使用 RVC-WebUI 進行研究，為徹底了解背後原理，並貫徹實驗精神，學生開始策畫一連串的簡單研究小專案。

2. RVC-WebUI 重點整理

研究資料於研究方法處論述因許多模型在高音頻段出現音色破裂等問題，故在多重篩選後剩下 RVC-WebUI 及 Applio 作為主要轉換技術，這兩項都是基於 RVC (Retrieval-based Voice Conversion, 檢索音聲轉換) 技術，透過輸入乾淨的訓練資料 (聲音)，讓模型訓練並產生向量索引檔案 (Vector Index)，完成後，輸入想要生成的音源資訊，模型會比對來源音訊特徵，用 Top-K 檢索找出資料庫中最相似的目標聲音特徵進行替換。

整體的生成模式會分成兩個部分，共六個步驟，第一個部分，一是 Content Feature Extraction (based on ContentVec)，他會提取目標音源¹的純粹內容資訊，二是 Pitch Extraction (音高提取)，提取目標音源乾淨的人聲音高資訊，而後生成索引檔案 (index)、模型檔案 (.pth)。第二部分共有四個步驟，前兩個步驟與第一部分一樣，對來源音訊²進行內容資訊提取、音高提取。第三個步驟是 Retrieval Module，也就是剛剛提到的透過向量索引檔案去檢索並找出最適合的目標特徵進行加權組合。最後則是 Acoustic Model and Vocoder 聲碼器，將特徵與音高重建成音訊，並減少誤差或是毀損。

我會想要舉個例子，例如在樂高積木當中，可以隨意的組裝及拼湊，訓練資料就像是一箱各有不同的樂高積木，而輸入音源如同一棟 101、一輛保時捷的範例圖片，模型會用現有的積木磚塊去盡可能的拼湊出最像是 101、保時捷的樣子。而我們在一開始取樣就像是決定我們現有哪些樂高磚塊。總結來說，我認為他像是一個模組化的歷程。

第一部分模型訓練完成後，會出現兩個檔案，分別是【.pth】、【.index】檔案，pth 檔案包含目標音色的主要神經網路權重檔案，index 則是前面提到的向量檢索機制特徵檔案。第二部分會調用第一部份的檔案去進行加權。

¹ 目標音源：欲產生的人聲。例如胡金銓聲線即為目標音源。

² 來源音訊：欲生成的音樂範例。例如研究資料中的主題曲。

我們可以特別來討論 ContentVec 的內容提取，也就是第一步驟。語音轉換常用模型 HuBERT 是基於 metaAI 的語音模型，但是當我們使用 HuBERT 提取特徵，其仍然會保留原說話者的身分特徵，也就是說，當我們的來源音訊使用這個模型提取，我們可能會在結果中聽到除了目標音聲之外的聲音，即來源音訊的原唱，也就是音色洩漏。這對於目標是讓目標音訊完全歌唱曲子的實驗來說非常的苦惱，於是有了 ContentVec，它具有微調機制，可以減少來源說話者的音色資訊，只擷取說話的內容、咬字、節奏等。

3. 專案想法即目標

來源目標我想要使用內建 UVR5 分離藝人的音聲，並讓他們的聲音透過 RVC 演唱一些歌曲。

為保護著作權、人格權，本實驗產生檔案不發布於任何公開平台。根據中華民國著作權法第 52 條³、第 46-1 條⁴僅做用於學術用途。而根據著作權法第 64 條⁵及學術倫理，此實驗將會標明出處以及使用方式。

4. 使用工具與方法

訓練電腦規格

名稱	型號	備註
CPU	Intel I7-9750H	6C12T @ 2.6 GHz
GPU	Nvidia RTX2060	6 GB VRAM
RAM	DDR4 2666	32GB 雙通道
Storage	1TB HDD + 1TB M.2 SSD	-

版本資訊

名稱	版本	備註
Python	3.14.0	Pip 26.1.2
RVC-WebUI	2.2.231006	Latest release Github
System	Windows 11 -26200.8737	
Nvidia Cuda toolkit	13.3.1	

目標音訊訓練檔案 A (TargetA)

檔案名稱	類型	人名	來源	代稱/檔案名稱
001-R	flac	湊友希那(虛擬) 相羽愛奈(CV.)	Für immer 專輯 單曲	SongA1
01.Sage der Rosen	flac	湊友希那(虛擬)	Für immer 專輯	SongA2

³ 中華民國著作權法第 52 條「為報導、評論、教學、研究或其他正當目的之必要，在合理範圍內，得引用已公開發表之著作。」

⁴ 中華民國著作權法第 46-1 條「依法設立之各級學校或教育機構及其擔任教學之人，為教育目的之必要範圍內，得公開播送或公開傳輸已公開發表之著作。但有營利行為者，不適用之。」


⁵ 中華民國著作權法第 64 條「依第四十四條至第四十七條、第四十八條之一至第五十條、第五十二條、第五十三條、第五十五條、第五十七條、第五十八條、第六十條至第六十三條規定利用他人著作，應明示其出處。」

		相羽愛奈(CV.)	單曲	
003-Neo-Aspect	flac	湊友希那(虛擬) 相羽愛奈(CV.)	Für immer 專輯 單曲	SongA3

來源音訊訓練檔案 (Source)

檔案名稱	類型	人名	來源	代稱/檔案名稱
視界の隅 朽ちる音	flac	井芹仁菜(虛擬) 理名(CV.)	專輯-<視界の隅 朽ちる音>	SongS1
空の箱	flac	芹仁菜(虛擬) 理名(CV.)	專輯-<空の箱>	SongS2

二、過程及數據



1. 先對目標音訊、來源音訊進行 UVR (Ultimate Vocal Remove) 模型分離目標人聲。

在對 targetA 進行模型分離伴唱人聲時，發現無法找到中繼的 temp 檔案，根據開發者的描述，UVR 系統似乎在某些時候會產生 bug，例如檔案名稱並非簡單的數字或是英文組合，而是包含特殊字元，會產生報錯，所以每一個檔案都使用 song 名字作為開頭的取代字取代原本名稱；我又發現，當資料夾路徑的任意檔案夾具有空格 space，也會出現大量報錯，並有機率無法成功建置。


原先我使用兩個 target 去做測試，也就是有 targetB 存在，不過後來發現 target 內的大量音源具有合唱，導致輸出結果容易汙染，所以果斷刪除 targetB。有趣的是，無論我使用哪種檔案去 UVR 生成，都會在 web 端產生大量報錯，但是檔案都是成功建置的，而開發者似乎也放棄對於 UVR 的漏洞進行更新，畢竟它可以成功達到效果。使用的模型是 HP5_only_main_vocal。

在第一次對 Source 做 UVR 的處理後，放入模型進行訓練，發現最後得到的純音樂檔案有一些毀損情況，原因可能是因為 UVR 進行人聲分離時，因為背景音樂的樂器在處理時發生削切，導致某些頻段聲音產生毀損，導致最後合成出來的結果有許多雜訊，並在播放中會使體驗受到嚴重影響。所以為此，我決定使用 UVR5 的軟體，並使用 UVR-MDX-NET inst HQ5 進行 instrumental 分離。經過測試二，明顯可以感受到 instrumental 的訊號比較正常，沒有撕裂或聲音毀損。

	測試一	測試二
對 targetA 模型	HP5	HP5+onnx_dereverb
對 Source instrumental 模型	HP3+dereverb	UVR-MDX-NET inst HQ5
對 Source vocal 模型	HP3+dereverb	UVR-MDX-NET Voc FT




內建的 UVR 介面




UVR5 軟體 使用 UVR-MDX-NET inst HQ5

2. 對 target 執行訓練。

使用 UVR 將人聲分離後，將僅具有人聲的檔案丟給模型進行訓練，生成索引檔案以及模型檔案。



訓練示意圖，左邊為監視窗、右邊為 webUI



名稱	狀態	CPU	記憶體	硬碟
Python (6)		14.3%	4,117.4 MB	0.1 MB/s
Python (22)		1.9%	1,971.2 MB	0.1 MB/s
Python		0%	1,950.2 MB	0.1 MB/s
Discord (6)		0.4%	316.0 MB	0.1 MB/s
使用者管理		0.3%	275.9 MB	0.1 MB/s
Windows 服務管理		0%	244.3 MB	0.1 MB/s
Antimalware Service Execut...		0.4%	156.5 MB	0.1 MB/s
Steam Client WebHelper (7)		0%	102.3 MB	0.1 MB/s
Security System		0%	99.9 MB	0.1 MB/s
工作管理		1.1%	93.9 MB	0.1 MB/s
Microsoft Teams (10)		0%	87.6 MB	0.1 MB/s
Microsoft Word		0%	82.4 MB	0.1 MB/s
檔案 (7)		0%	73.1 MB	0.1 MB/s
檔案 (7)		0%	52.7 MB	0.1 MB/s
檔案 (7)		0%	50.0 MB	0.1 MB/s
檔案 (7)		0%	47.1 MB	0.1 MB/s
檔案 (7)		0%	45.6 MB	0.1 MB/s
檔案 (7)		0%	40.1 MB	0.1 MB/s
檔案 (7)		0%	39.5 MB	0.1 MB/s
檔案 (7)		0%	39.4 MB	0.1 MB/s

執行訓練時的電腦消耗

以下為訓練參數：

參數	數值	說明
取樣率	40 k	取樣率的選擇基本上不影響訓練結果。
保存頻率	5	經過五次的訓練 (epoch) 會儲存一次的訓練

		檔案及索引檔案。
訓練輪數	20	在 RVC 下，大致上可以做到 20 輪訓練可以模擬出不錯的成果，這也是 RVC 的優點特徵。
Batch size	4	因為訓練硬體是僅有 6GB VRAM 的顯示卡，對於 GPU 的平行運算及顯存大小要有所顧慮，選擇四次的批次大小進行訓練。如果是有規模的 GPU 應該可以有效的縮小時間。
訓練時間	第一次:22 min 第二次:11 min	

第一次訓練與第二次訓練差異僅在目標音源的處理是否經過 Dereverb 模型。目前不確定兩次訓練時間相差一倍的問題。

3. 模型推理



推理頁面

使用目標音源的索引及模型去運算來源 vocal，並生成一個 wav 檔案。

4. 使用 DAW 進行混音



使用 audacity 進行混音

原本想要使用正規 DAW 去進行混音，但礙於資金不足，所以選擇免費的 Audacity 進行混音，而動作也非常簡單，將已經推理出的 wav 歌唱檔案放入一個音軌，並將在 UVR 階段已經分離的 instrumental 放入音軌，並在第一音軌加入 reverb 效果來增

加真實性以及觀賞性，最後匯出全部的聲音為 wav 檔案。

結果展示：

https://drive.google.com/file/d/1t4mdH4MB0vgnrahRA4JpDRFQMleNBnVV/view?usp=s_haring

三、結論及問題

1. 推理後生成出來的模仿音源還是存在濃厚的 AI 味道，在些許部分會存在之前就提到的雜訊（劈哩）聲，在經過混音和調整音量、EQ 可以解決大部分的問題。也許增加訓練的樣本、透過剪輯剔除合唱部分、用更多的模型去把目標音源整理乾淨也許是個不錯的方法，因為對於 target 音源，我並沒有將許多合唱部分刪除，所以導致無論 UVR 如何去將主人聲凸顯，也會含糊的帶入其他樂手的合唱，再來是使用內建的模型去跑 UVR，可能會讓 vocal 檔案還是有一些的樂器、人聲殘響，回歸使用 UVR5 本地端軟體也許是個好方法。也許做到以上這些點這樣可以降低生成汙染的問題。
2. 學生經過這次的小型實驗後發現，相比起 AI 模型的建置以及設定，用於訓練的材料乾淨程度很大一部分影響了 AI 之後的產物，若能盡量把 AI 輸入整理的更加完美，也許產物才能貼近我們想要的。
3. 增加 RVC 的訓練次數是否會讓產生的模型檔案及索引檔案更加完美、改變硬體規格去增加 batch_size 是否可以有更好的結果。等問題都沒有辦法透過這場實驗解釋。
4. 是否應該要直接把所有的音檔透過更加全面的 UVR5 處理，並提前使用軟體剪輯作為訓練素材。

四、未來發展

1. 因為學生僅花了一天左右時間在這份實驗報告，所以並沒有太多的著重於前期的訓練素材篩選、以及後期的剪輯，所以無法完全發揮模型以及 AI 的實力，也許可以加入上述的改進方法以及參考他人經驗，去完成更好的 AI 聲音。
2. 發現在 MDX-NET 還有許多模型可以分離樂器、聲音、去殘響，如果未來有時間可以去熟悉應用這些內容，去作出更多的應用，例如抓和弦、甚至更進階的音樂生成訓練。
3. 在批量處理上面，也許還有一些空間。一是基於 webUI，批量處理似乎沒有辦法穩定運行，至少在我這端會顯示錯誤（out of memory），也許可以做到本地端的批量化處理。從抓取目標音源、進入 UVR、生成索引檔案、抓取來源音訊、生成最終結果，也許可以透過 Agent 去自動化執行。這樣可以免於大量的時間浪費（本地端的運算消耗電力及大量時間，平常使用也需要占用顯示卡，若能於電腦的離峰時間如深夜、自動運行也許更佳）。

五、參考資料

1. RVC-Project. (2024). Retrieval-based voice conversion WebUI [Computer software]. GitHub.
<https://github.com/RVC-Project/Retrieval-based-Voice-Conversion-WebUI>
2. MDX_Net 系列模型的特点、优势和适用场景介绍。
<https://www.yuntts.com/105.html>
3. Ultimate-vocal-remover-gui , UVR5 [computer software] . GitHub.
<https://github.com/Anjok07/ultimatevocalremovergui>
4. 使用 AI 歌聲轉換技術將〈大醉俠〉主題曲轉換為 胡金銓導演聲線之實驗研究
Experimental Research on Converting the Theme Song of “Come Drink With Me” to
Director King Hu's Voice Using AI Singing Voice Conversion Technology.

AI Use Statement

本文架構皆為人工製作及審查，沒有任何文字基於 AI 生成。

使用之 AI 工具包含【Google Gemini / NotebookLM】。

使用 AI 的範圍僅限於整理資料、除錯、給予建議等。

本文資訊基於程式事實而陳述。若有問題或錯誤歡迎指教。

本文之架構文字屬於 中原電機 11428109 潘宇綸。

本文所有使用之工具、素材僅用於教育用途、無營利、無惡意重製散播之行為。

聲明:本專題報告之內容、圖片具有個資，禁止任意非經同意的轉載，謝謝。